

Petite synthèse de la méthodologie

Dans ce projet, l'objectif est de développer un système de détection automatique des contenus toxiques en anglais à partir de textes. Pour cela, nous utilisons plusieurs datasets afin de couvrir différents types de contenus problématiques : Jigsaw pour la toxicité générale, OLID pour le langage offensif, TRAC pour l'agression et YouTube Threat Corpus pour les menaces.

Après la collecte des données, les textes sont nettoyés et regroupés dans deux fichiers. Le premier fichier, `phase1_binary.csv`, est utilisé pour entraîner un modèle de classification binaire capable de distinguer les textes toxiques des textes non toxiques. Les labels sont : `0 = non-toxic` et `1 = toxic`. Le deuxième fichier, `phase2_toxic_types.csv`, est utilisé pour entraîner un autre modèle capable d'identifier le type de toxicité : `0 = offensive/abusive`, `1 = aggression` et `2 = threat`.

La méthodologie proposée commence par un pré-entraînement supplémentaire d'un modèle BERT déjà pré-entraîné. Cette étape est inspirée de HateBERT. Le but n'est pas d'entraîner BERT depuis zéro, mais de continuer son apprentissage sur tous les textes collectés, sans utiliser les labels. Cela permet au modèle d'apprendre le vocabulaire et le style des contenus toxiques présents sur les réseaux sociaux.

Après cette étape, on obtient un modèle adapté au domaine, que l'on peut appeler `toxic-domain-bert`. Ensuite, ce modèle est copié en deux versions séparées. La première version est fine-tunée sur `phase1_binary.csv` pour détecter si un texte est toxique ou non. La deuxième version est fine-tunée sur `phase2_toxic_types.csv` pour détecter le type de toxicité.

Ainsi, le système final contient deux modèles différents : un modèle spécialisé dans la détection binaire de toxicité, et un modèle spécialisé dans la classification des types de toxicité. Cette séparation permet d'avoir une architecture plus claire et plus adaptée à chaque tâche.

Partie expérimentale : Résultats et évaluation de l'article XAI

1. Objectif

L'objectif de cette partie est d'évaluer les performances de plusieurs modèles de machine learning et de deep learning dans la détection automatique du discours haineux sur les réseaux sociaux.

Les auteurs cherchent aussi à montrer l'importance de l'**intelligence artificielle explicable** ou **XAI**. Le but n'est donc pas seulement d'obtenir une bonne précision, mais aussi de comprendre pourquoi un modèle classe un message comme haineux, offensant ou normal.

Ainsi, l'objectif principal est de comparer différents modèles de classification et d'analyser leur capacité à détecter le discours haineux tout en fournissant des explications compréhensibles pour l'utilisateur.

2. Dataset utilisé

Les auteurs utilisent deux datasets principaux : **Google Jigsaw Dataset** et **HateXplain Dataset**.

Google Jigsaw Dataset est un dataset issu d'un challenge Kaggle. Il contient des commentaires provenant de discussions Wikipédia. Les commentaires sont classés selon plusieurs catégories de toxicité : **toxic**, **severe toxic**, **obscene**, **threat**, **insult** et **identity hate**.

Ce dataset est utilisé pour entraîner et comparer plusieurs modèles de classification classiques et profonds, comme Decision Tree, KNN, Random Forest, Naïve Bayes, Logistic Regression et LSTM.

HateXplain Dataset est un dataset composé de publications provenant de **Twitter** et **Gab**. Il contient plus de **20 000 textes** classés en plusieurs catégories : **hateful**, **offensive**, **normal** et **undecided**.

Ce dataset est utilisé principalement pour l'évaluation de l'explicabilité, car il contient des annotations qui permettent d'analyser les raisons des décisions du modèle.

Ainsi, Google Jigsaw est utilisé pour mesurer les performances des modèles de classification, tandis que HateXplain est utilisé pour étudier la détection du discours haineux avec des méthodes explicables comme **LIME** et des modèles basés sur **BERT**.

3. Méthodologie

La méthodologie suivie par les auteurs repose sur plusieurs étapes.

Dans un premier temps, les datasets sont chargés au format CSV à l'aide de la bibliothèque **Pandas** en Python.

Ensuite, les données sont nettoyées et prétraitées. Les auteurs suppriment les lignes contenant des valeurs manquantes, les liens URL, les caractères inutiles, les espaces supplémentaires et les stopwords. Les textes sont ensuite transformés en tokens afin de les rendre exploitables par les modèles.

Les auteurs appliquent aussi la **lemmatisation**, qui consiste à transformer les mots en leur forme de base. Par exemple, les mots "hated", "hating" et "hates" peuvent être réduits à "hate".

Après le prétraitement, les données sont transformées en valeurs numériques grâce à des méthodes de vectorisation comme **Count Vectorizer** et **TF-IDF**. Cette étape est nécessaire, car les modèles de machine learning ne peuvent pas traiter directement du texte brut.

Ensuite, plusieurs modèles sont entraînés sur le dataset Google Jigsaw : **Decision Tree**, **K-nearest neighbors**, **Random Forest**, **Multinomial Naïve Bayes**, **Logistic Regression** et **LSTM**.

Pour le dataset HateXplain, les auteurs utilisent des modèles basés sur **BERT**, notamment **BERT + MLP** et **BERT + ANN**. Ils utilisent aussi la méthode **LIME** afin d'expliquer les prédictions des modèles en identifiant les mots qui influencent la décision finale.

4. Métriques

Les auteurs utilisent plusieurs métriques pour évaluer les performances des modèles.

La première métrique est l'**accuracy**, qui mesure le pourcentage de prédictions correctes réalisées par le modèle.

La deuxième métrique est la **precision**, qui mesure la capacité du modèle à éviter les faux positifs, c'est-à-dire les cas où un message est classé à tort comme haineux.

La troisième métrique est le **recall**, aussi appelé sensibilité. Il mesure la capacité du modèle à détecter correctement les vrais messages haineux.

Les auteurs utilisent également le **F1-score**, qui combine la précision et le recall. Cette métrique est importante lorsque les classes sont déséquilibrées.

Enfin, pour l'explicabilité, les auteurs utilisent des méthodes comme **LIME** et le benchmark **ERASER**, qui permettent d'évaluer la qualité des explications fournies par les modèles.

5. Résultats

Les résultats montrent que les modèles de deep learning obtiennent de bonnes performances dans la détection du discours haineux.

Sur le dataset **Google Jigsaw**, le modèle **LSTM** obtient les meilleures performances globales avec une accuracy d'environ **97,6 %**. Il obtient aussi une precision de **0,85**, un recall de **0,83**, un F1-score de **0,84** et une specificity de **0,82**.

Modèle	Accuracy	Precision	F1-score	Recall	Specificity
Decision Tree	0,89	0,83	0,81	0,78	0,86
K-nearest neighbors	0,90	0,88	0,83	0,78	0,83
Random Forest	0,91	0,90	0,85	0,80	0,87

Modèle	Accuracy	Precision	F1-score	Recall	Specificity
Multinomial Naïve Bayes	0,96	0,79	0,75	0,72	0,70
Logistic Regression	0,97	0,74	0,72	0,70	0,72
LSTM	0,97	0,85	0,84	0,83	0,82

Les résultats montrent que **LSTM** est le modèle le plus performant en termes d'accuracy. Cependant, **Random Forest** obtient la meilleure precision avec un score de **0,90** et le meilleur F1-score avec **0,85**.

Sur le dataset **HateXplain**, les modèles basés sur BERT donnent également de bons résultats. Le modèle **BERT + MLP** obtient une accuracy de **93,67 %**, tandis que **BERT + ANN** obtient une accuracy de **93,55 %**.

Modèle	Accuracy
BERT + MLP	93,67 %
BERT + ANN	93,55 %

Même si **BERT + MLP** obtient une accuracy légèrement supérieure, les auteurs indiquent que **BERT + ANN** donne de meilleurs résultats en termes d'explicabilité.

La méthode **LIME** permet aussi d'expliquer les décisions des modèles. Elle montre les mots qui ont le plus influencé la classification d'un commentaire. Par exemple, certains mots offensants ou haineux reçoivent un poids plus important dans la décision du modèle.

6. Évaluation

L'évaluation montre que les modèles de deep learning sont très efficaces pour détecter le discours haineux sur les réseaux sociaux.

Le modèle **LSTM** donne les meilleurs résultats sur le dataset Google Jigsaw en termes d'accuracy. Cela montre que les réseaux de neurones récurrents sont capables de bien traiter les textes et de reconnaître les formes de toxicité dans les commentaires.

Les modèles **BERT + MLP** et **BERT + ANN** donnent aussi de bons résultats sur HateXplain. Ces modèles sont performants parce que BERT comprend le contexte des mots dans une phrase, ce qui est important pour détecter les messages haineux ou offensants.

Cependant, l'article montre que la performance seule n'est pas suffisante. Dans un domaine sensible comme la détection du discours haineux, il est important de comprendre pourquoi un modèle prend une décision.

C'est pour cela que l'utilisation de **LIME** est importante. LIME permet d'expliquer les prédictions en indiquant les mots qui contribuent le plus à la classification. Cela rend le système plus transparent et plus fiable pour les utilisateurs et les modérateurs.

En conclusion, l'évaluation confirme que les modèles de deep learning, notamment **LSTM** et les modèles basés sur **BERT**, sont efficaces pour la détection du discours haineux. Toutefois, les méthodes

d'explicabilité comme **LIME** sont essentielles pour comprendre et justifier les décisions prises par ces modèles.