

Petite synthèse de la méthodologie

Dans ce projet, l'objectif est de développer un système de détection automatique des contenus toxiques en anglais à partir de textes. Pour cela, nous utilisons plusieurs datasets afin de couvrir différents types de contenus problématiques : Jigsaw pour la toxicité générale, OLID pour le langage offensif, TRAC pour l'agression et YouTube Threat Corpus pour les menaces.

Après la collecte des données, les textes sont nettoyés et regroupés dans deux fichiers. Le premier fichier, `phase1_binary.csv`, est utilisé pour entraîner un modèle de classification binaire capable de distinguer les textes toxiques des textes non toxiques. Les labels sont : `0 = non-toxic` et `1 = toxic`. Le deuxième fichier, `phase2_toxic_types.csv`, est utilisé pour entraîner un autre modèle capable d'identifier le type de toxicité : `0 = offensive/abusive`, `1 = aggression` et `2 = threat`.

La méthodologie proposée commence par un pré-entraînement supplémentaire d'un modèle BERT déjà pré-entraîné. Cette étape est inspirée de HateBERT. Le but n'est pas d'entraîner BERT depuis zéro, mais de continuer son apprentissage sur tous les textes collectés, sans utiliser les labels. Cela permet au modèle d'apprendre le vocabulaire et le style des contenus toxiques présents sur les réseaux sociaux.

Après cette étape, on obtient un modèle adapté au domaine, que l'on peut appeler `toxic-domain-bert`. Ensuite, ce modèle est copié en deux versions séparées. La première version est fine-tunée sur `phase1_binary.csv` pour détecter si un texte est toxique ou non. La deuxième version est fine-tunée sur `phase2_toxic_types.csv` pour détecter le type de toxicité.

Ainsi, le système final contient deux modèles différents : un modèle spécialisé dans la détection binaire de toxicité, et un modèle spécialisé dans la classification des types de toxicité. Cette séparation permet d'avoir une architecture plus claire et plus adaptée à chaque tâche.